Simulação opinião pública sobre a percepção dos brasileiros acerca da democracia

Lucas Nascimento Aguiar[1], **Matheus dos Santos Moreira**[1]

[1] Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie

lucas.naguiar@outlook.com, matheusmoreira2004@live.com

Abstract. *This paper investigates the feasibility of using supervised machine learning techniques and large language models (LLMs) to simulate public opinion patterns regarding democracy in Brazil, using data from the CESOP/IPEC/04832 survey. The performance of a Random Forest classifier, structured via Classifier Chain, was compared against the LLaMA 3 model. Evaluation was conducted at two levels: individual, through accuracy, and distributional, using Jensen-Shannon Divergence (JSD). Results indicate that the supervised model outperformed the LLM in both metrics, showing higher accuracy (17.0% and 28.0% vs. 10.5% and 24.0%) and significantly lower JSD values (0.0365 and 0.0268 vs. 0.2674 and 0.1044). We conclude that specialized training on local data allows supervised models to more accurately capture the heterogeneity and nuances of the Brazilian sociodemographic landscape, whereas the LLM showed homogenization trends based on global training biases.*

Resumo. *Este trabalho investiga a viabilidade de utilizar técnicas de aprendizado de máquina supervisionado e modelos de linguagem de grande porte (LLMs) para simular padrões de opinião pública sobre a democracia no Brasil, utilizando dados da pesquisa CESOP/IPEC/04832. Foram comparados o desempenho de um classificador Random Forest, estruturado em uma cadeia de classificadores (Classifier Chain), e o modelo LLaMA 3. A avaliação ocorreu em dois níveis: individual, por meio da acurácia, e distribucional, utilizando a Divergência de Jensen-Shannon (JSD). Os resultados indicam que o modelo supervisionado superou o LLM em ambas as métricas, apresentando maior acurácia (17,0% e 28,0% contra 10,5% e 24,0%) e valores de JSD significativamente menores (0,0365 e 0,0268 contra 0,2674 e 0,1044). Conclui-se que o treinamento especializado em dados locais permite que modelos supervisionados capturem com maior fidelidade a heterogeneidade e as nuances do cenário sociodemográfico brasileiro, enquanto o LLM demonstrou tendências de homogeneização baseadas em vieses de treinamento global.*

1. Introdução

O objetivo deste trabalho é investigar a viabilidade de utilizar técnicas de aprendizado de máquina supervisionado e modelos de linguagem de grande porte (LLMs) para simular padrões de opinião pública sobre a democracia no Brasil. A proposta busca avaliar se tais modelos conseguem reproduzir tanto respostas individuais quanto distribuições agregadas de percepções, aproximando-se dos resultados obtidos em pesquisas reais de opinião.

A justificativa para este estudo consiste em explorar o uso de modelos de linguagem e generativos para simulação de pesquisas de opinião pública, permitindo avaliar o potencial e as limitações dessas ferramentas em cenários de alta complexidade social.

2. Metodologia

2.1. Base de dados e pesquisa de opinião pública

Os experimentos utilizaram os dados brutos da pesquisa de opinião pública intitulada "Percepção dos Brasileiros acerca da Democracia", registrada sob o número CESOP / IPEC / 04832. A coleta foi realizada entre os dias 01 e 05 de setembro de 2023, abrangendo um universo de eleitores com 16 anos ou mais em todo o território nacional.

O conjunto de dados totaliza 2.000 entrevistas individuais, conduzidas por meio de amostragem por conglomerados em três estágios, garantindo uma margem de erro de 2 pontos percentuais e um nível de confiança de 95%. A pesquisa coleta informações multidimensionais, incluindo perfis demográficos, socioeconômicos e comportamentais, além de percepções políticas específicas sobre prioridades para o país e o combate às *fake news*.

2.1.1. Separação do conjunto de treinamento e avaliação

Para garantir a comparabilidade entre as abordagens avaliadas, foi utilizado um mesmo conjunto de teste para o modelo supervisionado e para a simulação com LLM.

O *dataset* foi dividido em 90% para o conjunto de treinamento e 10% para o conjunto de teste. Dessa forma, assegura-se que as avaliações realizadas refletem o desempenho dos modelos em dados não utilizados durante o processo de modelagem.

Os dados da pesquisa foram carregados em um *Pandas Dataframe* por meio de um script Python e, utilizando as APIs da biblioteca *Scikit-learn*, foram divididos os conjuntos nas proporções mencionadas anteriormente. Os conjuntos foram escritos em formato *csv (Comma Separated Values)* e versionados no repositório público atrelado a pesquisa [Aguiar 2026] para facilitar a utilização em cada simulação.

A utilização de um conjunto de teste compartilhado permite uma comparação mais justa entre as abordagens, eliminando possíveis vieses decorrentes de diferenças na amostragem dos dados e garantindo consistência na análise dos resultados.

2.1.2. Preparação do dataset e seleção dos atributos

A seleção de atributos (*feature selection*) foi orientada pela natureza das variáveis coletadas no questionário da pesquisa. As variáveis foram categorizadas conforme sua escala de medição:

- **Variáveis Ordinais:** Foram selecionadas colunas onde a ordem das categorias possui significado intrínseco, como Faixa Etária (`FX_ID`), Nível de Interesse Político (`P4`), Renda Pessoal (`REND1`) e Renda Familiar (`REND2`).
- **Variáveis Nominais:** Foram selecionadas colunas sem ordenação natural, incluindo Sexo (`SEXO`), Escolaridade (`ESCOLARIDADE`), Raça (`RACA`), Religião

(RELIGIAO), Região (REGIAO), Condição do Município (COND) e a lembrança de votos para cargos do legislativo em 2022 (deputado estadual em P1A, deputado federal em P1B, e senador em P1C).

Os elementos alvo (*targets*) do modelo foram definidos como as variáveis P2_1 (propostas que devem ser prioridade para políticos) e P3_1 (opções para o combate às *fake news*).

2.1.3. Categorias raras e pré-processamento

Para otimizar a performance dos modelos e reduzir a esparsidade das matrizes geradas, adotamos uma técnica de simplificação de categorias:

- ***Features* Nominais:** Categorias com frequência inferior a 5% foram agrupadas em um rótulo genérico denominado "Outros".
- ***Targets*:** Categorias com frequência inferior a 3% foram consolidadas sob a etiqueta "Outros/Diversos".

O pré-processamento foi estruturado em um *pipeline* de transformação utilizando a classe ColumnTransformer [scikit-learn developers 2026b]. As variáveis ordinais passaram por um OrdinalEncoder [scikit-learn developers 2026e], respeitando as hierarquias pré-definidas. Já as variáveis nominais foram processadas via OneHotEncoder [scikit-learn developers 2026d], com a estratégia de exclusão da primeira coluna (*drop='first'*) para mitigar problemas de colinearidade.

2.2. Modelo Supervisionado

O modelo escolhido para a simulação de respostas da pesquisa utilizando aprendizado supervisionado foi o *RandomForestClassifier* [scikit-learn developers 2026f], configurado com class_weight=balanced para lidar com possíveis desbalanceamentos nas classes. Para tratar a natureza multi-saída do problema, utilizou-se a técnica de *Classifier Chain* [scikit-learn developers 2026a], no qual, considerando apenas dois alvos, o resultado de classificação do primeiro alvo alimenta o modelo para classificar o próximo.

2.2.1. Ajuste de Hiperparâmetros

O ajuste dos hiperparâmetros do classificador foi realizado de forma sistemática explorando diferentes combinações de parâmetros para os atributos do modelo. O método utilizado, *GridSearchCV* [scikit-learn developers 2026c], foi aplicado uma combinação diferente de valores para cada um dos atributos:

- número de estimadores (n_estimators);
- profundidade máxima (max_depth);
- número mínimo de amostras por folha (min_samples_leaf);
- critérios de complexidade (ccp_alpha).

2.2.2. Validação Cruzada

Para tentar evitar que o modelo fosse treinado por uma quantidade ainda menor de dados, foi adotada validação cruzada com 5 *folds*, garantindo que cada um dos 5 subconjuntos fossem utilizados tanto para treino quanto para teste. Além de garantiar que todos os conjuntos fossem utilizados de maneira otimizada, a validação cruzada também diminui as chances de sobreajuste do modelo aos dados de treinamento.

2.2.3. Métricas de Avaliação

O método de avaliação padrão da biblioteca *Scilit-Learn* não suporta, de maneira nativa, problemas que envolvem múltiplas saídas. Como o problema tratado se encaixa nesse cenário (classificando os alvos `P2_1` e `P3_1`) foi necessário construir uma função de avaliação customizada para o cálculo do *F1-Score*. A implementação trata de utilizar a avaliação individual da métrica para cada um dos alvos, e então, calcular o resultado final a partir da média ponderada entre elas.

Formalmente, seja $Y = \{y_1, y_2, \ldots, y_m\}$ o conjunto de saídas verdadeiras e $\hat{Y} = \{\hat{y}_1, \hat{y}_2, \ldots, \hat{y}_m\}$ as saídas previstas, com m representando o número de alvos. O F1-Score customizado é definido como:

$$F1_{multi} = \frac{1}{m} \sum_{i=1}^{m} F1(y_i, \hat{y}_i)$$

onde $F1(y_i, \hat{y}_i)$ corresponde ao F1-Score ponderado calculado para o alvo i.

Além disso, foi empregado o cálculo da Divergência de Jensen-Shannon (JSD) para comparar a distribuição das classes reais e previstas, permitindo avaliar a capacidade do modelo em reproduzir a distribuição estatística de uma pesquisa de opinião.

2.3. Simulação com LLM

Neste trabalho, foi empregada a abordagem de *silicon sampling* para simular respostas de indivíduos a partir de um modelo de linguagem de grande porte (LLM), conforme proposto por Argyle et al. (2023). A base de dados utilizada foi uma pesquisa do CESOP sobre a percepção dos brasileiros acerca da democracia.

Para cada respondente de teste e para cada questão selecionada do questionário, foi construído um *prompt* estruturado em linguagem natural, contendo o perfil do indivíduo e a pergunta a ser respondida. Foram exploradas diferentes estratégias de construção do prompt, comparando uma abordagem estruturada em formato de lista (mapa de atributos) com uma abordagem em linguagem natural contínua, com o objetivo de avaliar o impacto da forma de apresentação das informações no desempenho do modelo.

O modelo LLaMA 3 foi utilizado localmente via Ollama, garantindo o uso exclusivo de ferramentas abertas e reprodutíveis. O modelo foi instruído a responder estritamente com uma das opções fornecidas, sem explicações adicionais, de forma a manter consistência com o formato original do questionário.

Um exemplo de prompt utilizado é apresentado a seguir:

```
Você é uma pessoa do sexo masculino, tem escolaridade
 ↪  Superior incompleto, religião Católica Apostólica
 ↪  Romana, é da faixa etária 55 A 64, é da raça Parda,
 ↪  renda pessoal de MAIS DE 1 A 2 salários mínimos, renda
 ↪  familiar de MAIS DE 2 A 5 salários mínimos, mora na
 ↪  região CENTRO OESTE do país, em um município com
 ↪  condição INTERIOR.
Você tem Muita vontade em participar da vida política.
Você se lembra em quem votou para Deputado Estadual nas
 ↪  eleições gerais de 2022.
Você se lembra em quem votou para Deputado Federal nas
 ↪  eleições gerais de 2022.
Você não lembra em quem votou para Senador nas eleições
 ↪  gerais de 2022.

Baseie sua resposta nas características do perfil e no
 ↪  comportamento típico de indivíduos semelhantes.

Pergunta:
...

Alternativas:
...

Responda com APENAS uma das opções exatamente como escrita.
Não explique sua resposta.
```

Devido à presença de lógica condicional no questionário original (*skip logic*), apenas perguntas com baixa taxa de valores ausentes foram consideradas na análise, garantindo a comparabilidade entre respostas reais e simuladas.

Após a geração das respostas, foi aplicada uma etapa de normalização textual para reduzir inconsistências superficiais, como prefixos numéricos e variações de formatação, permitindo uma comparação mais fiel entre as respostas do modelo e os dados reais.

Por fim, a avaliação do modelo foi conduzida tanto no nível individual, por meio da acurácia, quanto no nível distribucional, utilizando a Divergência de Jensen-Shannon (JSD) para comparar as distribuições de respostas reais e simuladas, onde valores mais próximos de zero indicam maior alinhamento entre as distribuições, enquanto valores mais elevados indicam maior divergência.

3. Resultados

3.1. Modelo Supervisionado

A implementação do modelo preditivo baseou-se no algoritmo ***RandomForestClassifier***, otimizado via técnica de ***GridSearchCV*** com validação cruzada de 5 *folds*. O modelo atingiu um *F1-Score* ponderado de $0,1994$ durante a fase de treinamento/validação. Os hiperparâmetros que definiram a melhor configuração do classificador foram:

- `n_estimators`: 100;

- `ccp_alpha`: 10^{-5};
- `max_depth`: 30;
- `max_features`: *'sqrt'*;
- `min_samples_leaf`: 1.

Abaixo, os resultados são detalhados para cada um dos alvos da simulação:

3.1.1. Alvo $P2_1$ (Propostas Prioritárias)

Para este alvo, o modelo apresentou uma acurácia de $0,17$ e um *F1-Score* médio ponderado de $0,16$. A análise das métricas por classe revelou uma variação heterogênea no desempenho:

- A categoria **"Melhorar a qualidade da saúde"** apresentou o desempenho mais robusto, com *recall* de $0,40$ e *F1-Score* de $0,29$. Isso sugere que as *features* sociodemográficas capturaram com maior clareza os padrões de resposta para esta preocupação central.
- Em contrapartida, categorias com baixa representatividade amostral, como **"Ampliar o uso de energias renováveis"** e **"Aumentar os impostos de grandes fortunas"**, resultaram em métricas de $0,00$. Tal comportamento evidencia a complexidade de generalização do modelo para eventos raros em um cenário de alta cardinalidade sem um agrupamento prévio de categorias.

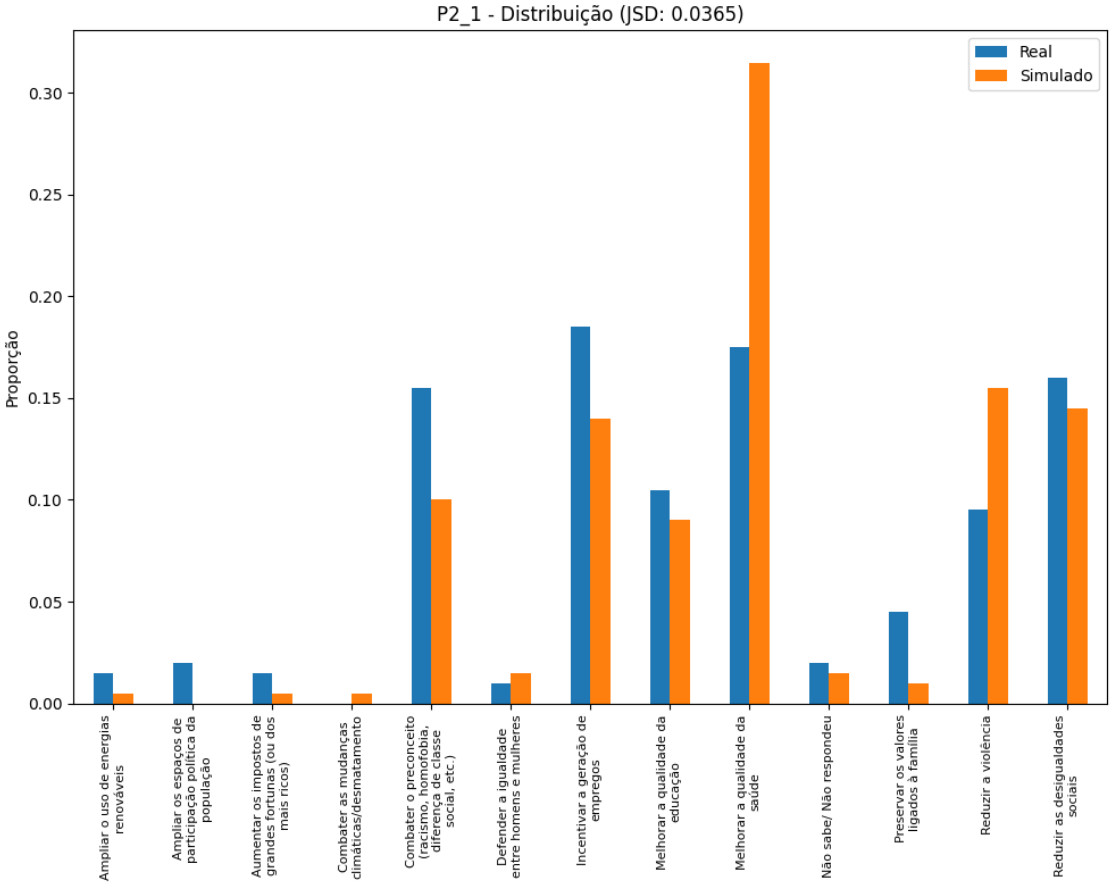

Figura 1. Comparação da distribuição de respostas reais e simuladas para a questão $P2_1$.

O resultado mais expressivo para a $P2_1$ foi a **Divergência de Jensen-Shannon (JSD)** de $0,0365$. Este valor, próximo de zero, demonstra que o modelo é altamente eficaz na simulação populacional. Embora a predição individual seja desafiadora, o modelo garante que a proporção das respostas simuladas preserve a fidelidade estatística do conjunto de dados original do CESOP, conforme ilustrado na Figura 1.

3.1.2. Alvo $P3_1$ (Combate às *Fake News*)

O segundo alvo obteve métricas superiores, com acurácia de $0,28$ e *F1-Score* ponderado de $0,26$, indicando uma correlação mais linear entre os atributos e este tema.

- A opção **"Ampliar a regulamentação... pelas plataformas digitais"** destacou-se com um *F1-Score* de $0,32$, sendo a tendência predominante capturada.
- A categoria **"Não sabe/Não respondeu"** apresentou o maior *recall* $(0,53)$, o que pode indicar que o perfil demográfico (como escolaridade e acesso à informação) é um forte preditor da incerteza do respondente sobre regulação digital.

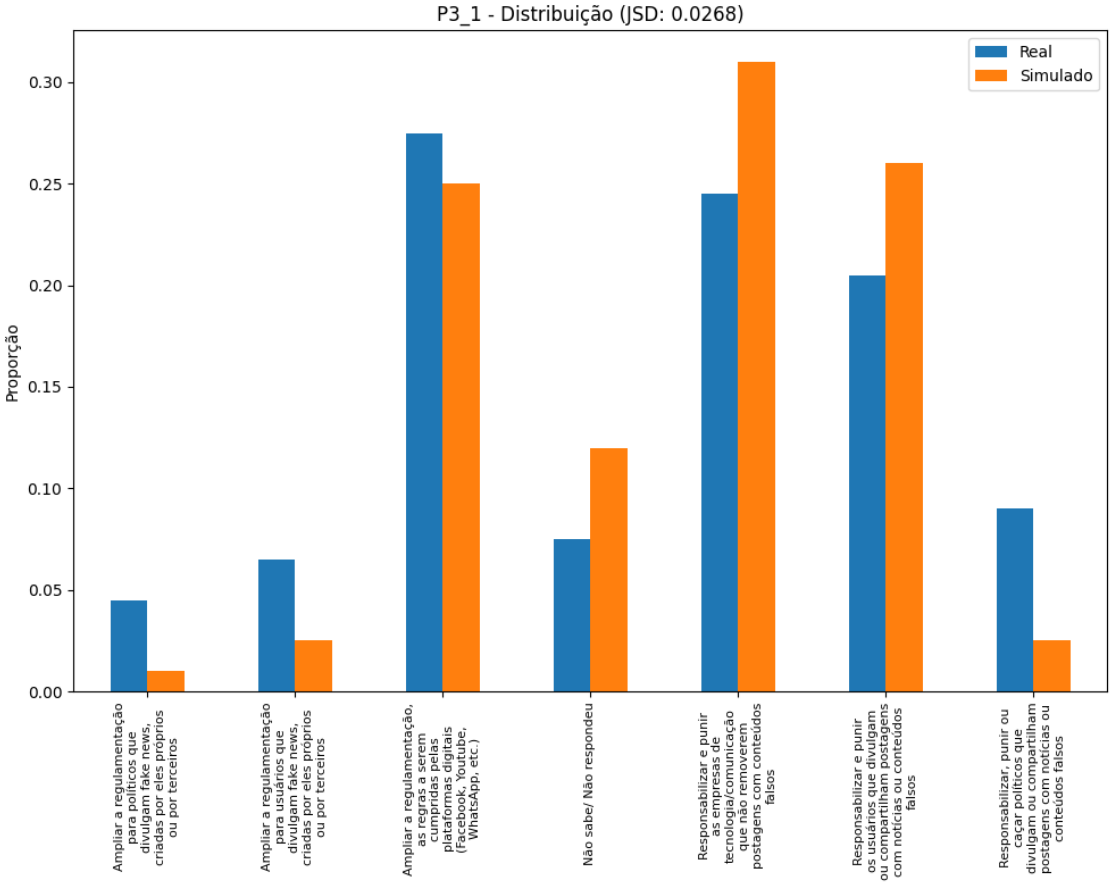

Figura 2. Comparação da distribuição de respostas reais e simuladas para a questão $P3_1$.

A métrica JSD para este alvo foi de $0,0268$, reforçando a capacidade do modelo de aprendizado supervisionado em aprender a ”curva de opinião”da sociedade. A simulação gerou uma base sintética que respeita as frequências relativas observadas empiricamente, confirmando a alta fidelidade macroscópica do modelo (Figura 2).

3.2. Simulação com LLM

A avaliação do modelo foi realizada em dois níveis: individual e distribucional. No nível individual, a acurácia global obtida pelo modelo foi de aproximadamente 17,2%, com acurácia de 10,5% para a questão P2_1 e 24% para a questão P3_1, evidenciando variação de desempenho entre diferentes tipos de perguntas.

No nível distribucional, foi utilizada a Divergência de Jensen-Shannon (JSD) para comparar as distribuições de respostas reais e simuladas. Os valores obtidos foram de aproximadamente 0,27 para a questão P2_1 e 0,10 para a questão P3_1.

Em uma configuração anterior, utilizando uma estrutura de mapa para o prompt, foi observada uma acurácia global de aproximadamente 18,5%. A acurácia individual das questões foram de 21% e 16% para as questões P2_1 e P3_1, respectivamente. A mesma estrátegia para medição de distribuição foi usada e os resultados foram de 0,17 e 0,26 para as perguntas P2_1 e P3_1, respectivamente. Essa variação reforça a sensibilidade

do modelo às escolhas de configuração, incluindo a estrutura e mudanças minimas ao prompt.

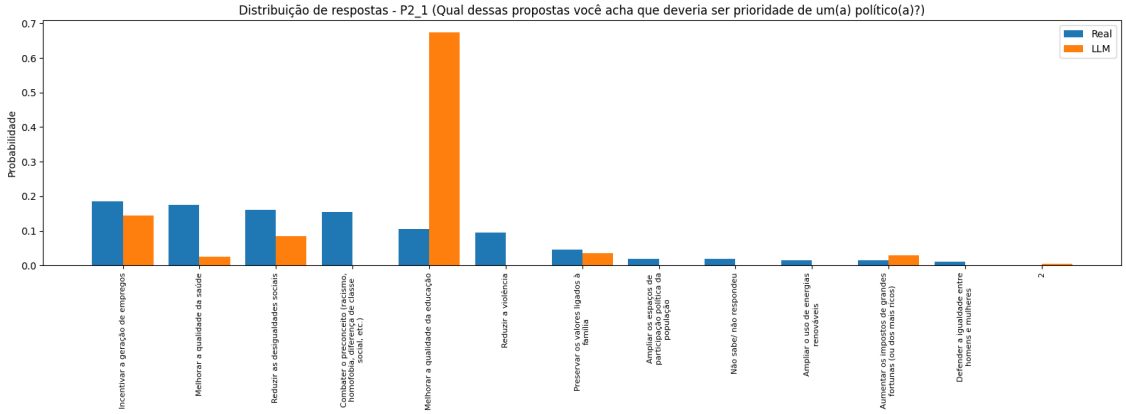

Figura 3. Comparação da distribuição de respostas reais e simuladas para a questão $P2_1$**.**

Como ilustrado na Figura 3, observa-se que o modelo é capaz de capturar parcialmente a distribuição das respostas, reproduzindo as categorias mais frequentes do dataset. No entanto, há uma tendência de superestimação em determinadas opções, como aquelas relacionadas à qualidade de educação, enquanto outras categorias relevantes, combater o preconceito, são sub-representadas ou ignoradas. Esse comportamento indica que o modelo prioriza temas mais salientes, mas não consegue preservar completamente a diversidade presente nas respostas reais.

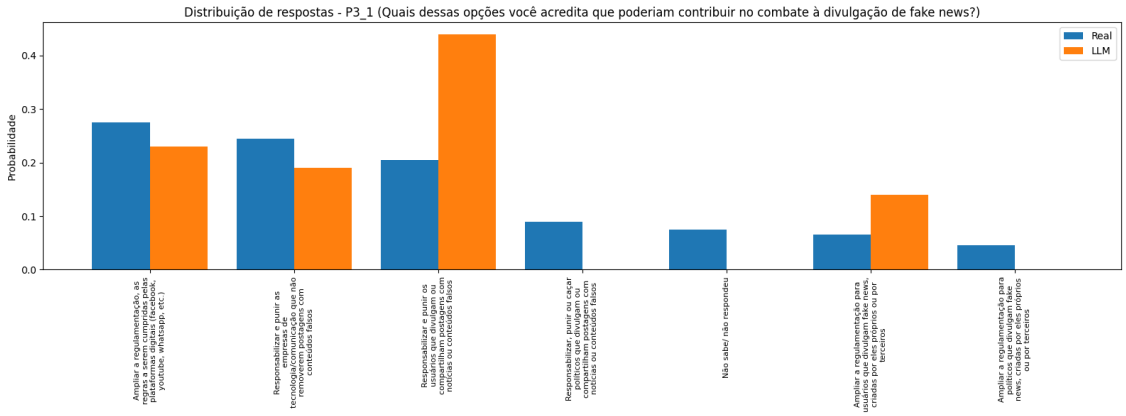

Figura 4. Comparação da distribuição de respostas reais e simuladas para a questão $P3_1$**.**

Como ilustrado na Figura 4, observa-se maior alinhamento entre as distribuições real e simulada na questão P3_1 em comparação à questão P2_1, o que é consistente com os valores de JSD obtidos.

Observa-se que o modelo tende a concentrar respostas em um subconjunto reduzido de categorias, superestimando opções mais gerais e subestimando categorias mais específicas. Esse comportamento é particularmente evidente na questão P3_1, onde uma

única categoria concentra uma proporção significativamente maior de respostas simuladas em comparação com os dados reais.

Por fim, observa-se que o desempenho do modelo é sensível à forma como o prompt é construído. Pequenas alterações na estrutura do prompt, como a transição de um formato estruturado em lista para linguagem natural contínua, resultaram em variações relevantes nos resultados, evidenciando um trade-off entre acurácia individual e alinhamento distribucional.

4. Comparação dos Resultados

A análise comparativa entre o LLM (*LLaMA 3*) e o modelo de aprendizado supervisionado (*Random Forest*) foi realizada sob duas perspectivas: a acurácia de predição individual e a fidelidade da distribuição populacional (JSD). A Tabela 1 sintetiza as principais métricas obtidas.

Métrica	**Modelo LLM**		**Modelo Supervisionado**	
Questão	$P2_1$	$P3_1$	$P2_1$	$P3_1$
Acurácia	$0,105$	$0,240$	**0,170**	**0,280**
JSD	$0,2674$	$0,1044$	**0,0365**	**0,0268**

Tabela 1. Comparativo de Desempenho entre os Modelos

Na comparação em nível individual, o modelo supervisionado apresentou desempenho superior em ambos os alvos, atingindo maiores valores de acurácia nas tarefas de classificação. Na questão $P2_1$, observou-se que o LLM tendeu a concentrar suas predições em categorias pouco específicas e politicamente esperadas (como investimento em educação e geração de empregos), falhando em capturar a heterogeneidade das respostas reais baseadas no cenário sociodemográfico brasileiro. Em contraste, o modelo supervisionado, por ter sido treinado especificamente com dados do CESOP, conseguiu mapear correlações sociodemográficas mais sutis e representativas, resultando em um ganho de acurácia de aproximadamente 62% em relação ao LLM para este alvo.

Quanto à questão $P3_1$, ainda na comparação em nível individual, os modelos apresentaram resultados convergentes e não demonstraram disparidades acentuadas, embora o modelo supervisionado tenha mantido um desempenho ligeiramente superior ao LLM.

No nível distribucional, a métrica **JSD** revela a maior divergência entre as abordagens. Enquanto o LLM apresentou dificuldades em replicar a distribuição estatística da população (especialmente na $P2_1$, com $JSD = 0,2674$), o modelo supervisionado obteve valores de divergência extremamente baixos ($0,0365$). Isso evidencia que, para fins de simulação de opinião pública, o aprendizado supervisionado representou a realidade de maneira muito mais fiel, preservando as proporções originais das opiniões da sociedade brasileira.

A análise do modelo supervisionado permitiu, ainda, extrair informações sobre a importância relativa das variáveis utilizadas na predição. Observa-se que atributos relacionados a características socioeconômicas e ao comportamento político, como renda, escolaridade e interesse político, exercem maior influência nas decisões do classificador.

Essa interpretabilidade é uma vantagem inerente aos modelos supervisionados, permitindo compreender quais fatores contribuem para determinadas respostas, em contraste com os modelos de linguagem, cuja tomada de decisão é menos transparente.

Embora o modelo supervisionado apresente vantagem estatística em representar a distribuição da pesquisa de opinião utilizada, não é possível afirmar de forma conclusiva sua superioridade absoluta na reprodução de distribuições genéricas. A comparação direta é limitada pela pequena quantidade de dados utilizada no treinamento do modelo supervisionado e pelo desconhecimento dos vieses de treinamento do *LLaMA 3*. Ainda assim, os resultados sugerem que o treinamento especializado em conjuntos de dados representativos traz benefícios significativos na captura de fidelidade em cenários específicos, como o sociodemográfico brasileiro. O LLM, por sua vez, enfrenta desafios de localização por ser condicionado por dados de treinamento de âmbito global e com vieses próprios.

Cabe destacar que os experimentos foram realizados com uma única execução dos modelos, não sendo consideradas variações decorrentes de múltiplas amostragens ou técnicas como *bootstrapping*, o que constitui uma oportunidade para investigações futuras.

5. Conclusão

Este trabalho investigou a aplicabilidade de diferentes paradigmas computacionais na simulação de pesquisas de opinião pública. Os resultados obtidos permitem concluir que, para o conjunto de dados analisado, o modelo de aprendizado supervisionado supera o LLM (*LLaMA 3*) tanto na precisão das respostas individuais quanto na manutenção da integridade estatística das distribuições.

A superioridade do modelo supervisionado reside na sua capacidade de extrair padrões diretamente do contexto local, enquanto o LLM, embora versátil, reflete vieses de seu treinamento genérico que podem não espelhar as nuances da percepção democrática brasileira. Para a Computação Aplicada às Ciências Sociais, o baixo índice de JSD alcançado pelo modelo *Random Forest* o valida como uma ferramenta robusta para a geração de dados sintéticos e simulações populacionais.

Como trabalhos futuros, além da exploração de técnicas de *Fine-Tuning* e métricas de explicabilidade como *SHAP values*, sugere-se a investigação de **outras estruturas de engenharia de *prompt*** para otimizar a resposta dos modelos de linguagem. Além disso, propõe-se a realização de testes comparativos com **outras arquiteturas de LLMs** (como a família GPT ou Claude) para verificar se os desafios de distribuição observados são intrínsecos ao paradigma dos modelos de linguagem ou específicos da arquitetura testada neste estudo.

Referências

Aguiar, L. N. e. M. M. S. (2026). Projeto: Simulação de opinião pública. `https://github.com/olucasaguiar/projeto-simulacao-opiniao-publica`.

scikit-learn developers (2026a). Classifierchain. documentação do scikit-learn. `https://scikit-learn.org/stable/modules/generated/sklearn.multioutput.ClassifierChain.html`. Acesso em: 12 abr. 2026.

scikit-learn developers (2026b). Columntransformer. documentação do scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.compose.ColumnTransformer.html. Acesso em: 12 abr. 2026.

scikit-learn developers (2026c). Gridsearchcv. documentação do scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. Acesso em: 12 abr. 2026.

scikit-learn developers (2026d). Onehotencoder. documentação do scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html. Acesso em: 12 abr. 2026.

scikit-learn developers (2026e). Ordinalencoder. documentação do scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OrdinalEncoder.html. Acesso em: 12 abr. 2026.

scikit-learn developers (2026f). Randomforestclassifier. documentação do scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html. Acesso em: 12 abr. 2026.